

Research Memo

- 研究问题：**这个项目的核心是从消息流中提取结构化的行为单元，并利用订单生命周期信息来增强对单元的理解。我们最终的目标是推断市场参与者的意图，这需要将多个行为单元聚合起来分析。
 - RQ1：订单流中是否存在稳定、可重复的局部行为片段？
 - RQ2：这些行为片段能否构成跨股票 / 跨日期可复用的“行为词表”？
 - RQ3：行为片段之间是否存在方向性作用关系，例如 A 常诱发 B？
 - RQ4：这些行为关系图是否能提升对未来微观结果的预测，例如短期价格变动、成交概率、撤单潮、失衡反转？
 - RQ5（后期）：能否将行为片段进一步聚合为更高层的隐性的交易行为模式 / 意图代理指标，并赋予稳定的经济解释，例如推进、试探、撤退、被动承接、持续执行、短暂施压等？
- 数据结构：**Order 和 Trade 是沪深原始数据，Order_Launchered, Tick_Launchered, Trader_Launchered 是处理后的沪深数据。处理前的原始数据里面的信息会更多，处理数据的过程中做了一些合并等操作。原始数据用于行为单元的在线发现与关系建模；处理后订单生命周期数据用于对已发现行为单元进行后验画像、语义解释与弱监督构造，不直接参与在线 token 发现。
- 行为单元定义：**行为单元没有唯一正确性，因为市场微观结构连续 / 高维 / 多主体博弈，不存在天然的分词标准。所以我的目标是：构建一套合理、可验证、且与研究目标对齐的规则体系。
 - 与市场微观结构理论对齐：学术或实务文献支持，如果类似的模式在学术论文或券商研报中被提及，定义就有了理论基础。
 - 与交易逻辑对齐：规则符合交易员的直觉，比如如果一个“攻击波”的定义（连续大单、快速成交）在实盘交易中确实被看作是有冲击力的行为，那么它就是有意义的。
 - 统计显著性验证：需要证明，按照规则识别出的行为单元，在统计上与后续的价格运动、波动率变化等存在显著的相关性或预测能力。如果规则定义出的“攻击波”之后，价格上涨的概率显著高于 50%，那么这个定义就是有用的。
 - 行为单元的定义与切分只能依赖该时点及其之前可获得的信息，不能用未来结果定义单元。任何依赖订单后续成交路径、最终完成状态或当日结束后统计结果的字段，仅用于后验解释、弱监督构造或验证，不直接参与在线建模输入。
- 最终预测目标：**基于连续订单流中提取的行为单元及其相互作用关系，构建更高层的隐性交易行为模式（latent behavioral regimes / intent proxies）。研究重点在于回答：局部行为单元能否稳定地组织成具有方向性、层级性和预测价值的行为结构，以及这些结构是否能够对应到更高层的市场行为模式。模型的核心任务是先基于过去一段时间内识别出的行为单元序列及其上下文关系，学习行为单元之间的转移、共现、诱发和聚合机制；在此基础上，再

进一步探索是否能够形成更高层的隐性行为模式表示。若这一层表示足够稳定，则后续可以将其表达为若干 latent regimes / intent proxies 的概率分布，作为一种更高层的中间认知变量，用于支持短期价格行为预测、订单流状态预测、决策稳定性预测（当前模型发出的买入 / 卖出信号，在未来 N 分钟内被自己推翻的概率，但不确定这个预测目标是否可以达到或者是否科学）或其他下游任务。主顺序为：连续订单流 → 行为单元切分 → 行为词表学习 → 行为关系建模 → 高层隐性行为模式 / intent proxy 探索。

5. 评价指标：

- 表示层：行为单元切分与词表学习，检验我们提取的“行为词”是否语义清晰、稳定、有区分度。
 - 关键指标：
 - 跨样本稳定性：不同交易日、不同股票上相同单元的分布一致性。
 - 区分度。
 - 相对 baseline 增量预测力。
 - 基线对比：原始事件类型（NEW/CANCEL/TRADE）、固定时间窗口切分、随机切分。
 - A 股特殊点：需分时段（集合竞价 / 连续竞价）、分股票流动性、单独评估涨跌停附近的行为。
- 行为关系建模与意图推理：检验学到的单元表示能否有效预测未来市场状态，以及推断的“意图”是否与后续行为一致。
 - 关键指标：
 - 预测任务：未来 1 分钟收益率符号（AUC）、订单流不平衡（OFI）预测误差（MSE）。
 - 意图一致性：若模型推断出“拉升”意图，后续上涨概率应显著高于基准。
 - 基线对比：手工微结构特征（价差、订单簿不平衡）、固定窗口 LOB 特征、随机打乱单元序列。
 - A 股特殊点：排除涨跌停样本，处理午间休市的时间不连续性，分时段评估预测效果。
- 策略应用与可解释性：证明行为单元和意图能带来实际交易价值。
 - 关键指标：
 - 简单策略回测：基于意图信号（如“拉升”时买入，“出货”时卖出）的夏普比率、累计收益。
 - 市场影响分析：不同行为单元发生后 1 分钟内的价格冲击、价差变化。
 - 基线对比：随机交易、买入持有、传统因子策略（如动量）。
 - A 股特殊点：考虑 T+1 制度、交易成本（印花税 + 佣金）、涨跌停无法交易的情形。
- 统计显著性检验

- Block Bootstrap：按天分块重采样，计算指标置信区间。
- 跨样本验证：在不同年份、不同股票上验证结果稳定性。
- 多重检验校正：若同时测试多个策略，使用 Bonferroni 或 FDR 校正。

6. **可能经济含义**：不在于预测精准的涨跌幅，而在于理解市场博弈的本质，从而在信息不对称的市场中获得结构性的优势。

7. 实验步骤：

主线：

- Step0：建统一事件层：沪深数据不一样不能直接使用。
- Step1：定义局部 episode：哪一段连续事件构成一个候选局部行为片段。
- Step2：从 episode 学行为单元：先把一个局部 episode 表示出来，再把相似 episode 聚成行为词。
- Step3：做 token 的稳定性与有效性检验：换一天还能不能复现 / 换一支股票还能不能复现 / 比简单 baseline 强不强？
- Step4：行为关系建模：有了 token 序列，研究 token A 后面常跟什么 / 哪些 token 经常共同出现 / 哪些 token 诱发另一些 token？
- Step5：外部验证：输入 token 序列 / token graph / 局部上下文表示，输出对外部任务的预测结果：future return sign/OFI/ 短时波动率等。主线最重要的科学检验，保证这些行为单元确实有外部信息含量。

复线：

- Step6：用 lifecycle data 给 token 做画像，clean 数据最适合做的步骤。把 raw 发现出来的 token，映射回 clean 的订单生命周期画像。回答：这个 token 在生命周期上一般是什么样？
- Step7：（后期）更高层 latent regime / intent proxy，当 token 稳定，有预测力，且生命周期画像有一致性时可做，可以做概率分布。